INCT · NOTA DE PROJETO

MPC clássica e híbrida

Fundamentos, condições e roteiro de experimentos

Burgers 1D | Black–Scholes | PyTorch puro

Objetivo

Definir, implementar e comparar quatro modelos de regressão supervisionada que reconstroem soluções analíticas de equações conhecidas. A contribuição central a investigar é a parametrização polinomial de coeficientes clássicos ou quânticos independentes das entradas, não a solução de PDEs por PINNs.

Decisões já fixadas

Estrutura	Definição
Entrada	Apenas a MLP principal recebe x,t (ou S,τ).
Ramo quântico	Circuito auxiliar do termo i com exatamente i qubits; sem data encoding.
Acoplamento	$(1 + y_i) \cdot \langle P_i \rangle^i$, agregado por média (sum como ablação).
Treinamento	MSE contra solução exata; nenhum residual de PDE.
Implementação	PyTorch puro, CPU/CUDA, um run.py e um config.yaml.

Status da versão

Protótipo executável e testado em CPU, com simulação quântica por vetor de estado. Os números preliminares são diagnósticos de funcionamento, não evidência estatística de superioridade. CUDA está prevista no código, mas não foi validada com uma GPU neste ambiente.

28 de outubro de 2026

1. Ideia científica e relação com a literatura

O trabalho começa pelo esboço INCT (arquiteturas MLP, MPC clássica e MPC híbrida; problemas Burgers 1D/2D/3D e Black–Scholes). Adotamos inicialmente Burgers 1D e Black–Scholes, pois as soluções são conhecidas e permitem isolar o efeito arquitetural sem envolver o treinamento físico de uma PINN.

O que reter dos artigos enviados

• QPINN-MAC, Physical Review A (2026) [1]: introduz acoplamento multiplicativo-aditivo e relata benchmark de circuito RLC com PINN, QPINN e QPINN-MAC. O trabalho inclui residual de EDO e não equivale diretamente ao nosso protocolo supervisionado.

• QPI-DeepONet-MAC, arXiv 2610.01824 (2026) [2]: estende a discussão para operadores, com arquiteturas branch/trunk e resultados teóricos; seu escopo é mais amplo que uma rede de regressão em pontos.

• INCT (documento interno): modifica o acoplamento para potências sucessivas z_i^i e $\langle P_i \rangle^i$, além de explicitar os dois ramos em paralelo.

Qual é a pergunta central?

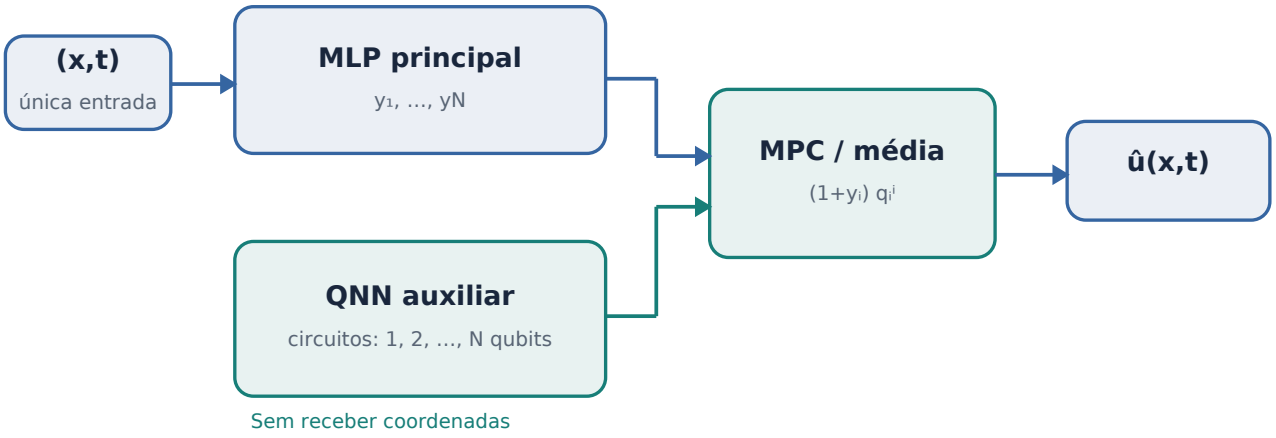
A construção quântica dos coeficientes estáticos pode alterar favoravelmente o treinamento da MLP principal? Se sim, em quais regimes (ordem, observável, qubits, profundidade e inicialização), e qual é o custo adicional da simulação?

Hipóteses operacionais

Hipótese	O que seria evidência
H1 - precisão	Menor RMSE / erro relativo no teste, repetido em várias sementes.
H2 - estabilidade	Menor dispersão entre sementes; gradientes úteis e curvas de validação estáveis.
H3 - contribuição do circuito	Diferença consistente entre circuito treinável, congelado e coeficientes clássicos.
H4 - custo-benefício	Ganho de erro que justifique tempo, parâmetros e memória adicionais.

Nem o teorema de aproximação universal nem um teste curto, isoladamente, demonstram ganho quântico ou vantagem computacional. Resultados estatísticos e controles apropriados serão indispensáveis.

2. Arquiteturas e definição matemática



MLP: uma única rede com entrada espacial-temporal e saída escalar. MPC clássica: a MLP principal gera $y_i(x,t)$, enquanto uma MLP auxiliar avaliada sempre na mesma constante gera $z_i(\varphi)$. MPC híbrida: trocam-se os z_i por medidas de circuitos quânticos auxiliares independentes das entradas.

$$\widehat{u}(x,t) = \frac{1}{N}\sum_{i=1}^{N}[1 + y_i(x,t;\theta)][q_i(\phi_i)]^i$$

$$q_i(\phi_i) = \langle 0|U_i^{\dagger}(\phi_i)P_iU_i(\phi_i)|0\rangle$$

Cada P_i é uma palavra de Pauli hermitiana em i qubits; por exemplo: P_1=Z, P_2=Z⊗Z e P_3=Z⊗Z⊗Z. Por construção, q_i não varia com x,t, embora varie durante a otimização dos ângulos φ_i. A saída padrão é a média; a soma é um controle opcional no YAML.

Termo	Qubits	Observável inicial	Potência
1	1	Z	q_1
2	2	ZZ	q_2^2
3	3	ZZZ	q_3^3
i	i	Palavra de i Pauli	q_i^i

A QNN convencional utilizada como referência é diferente: ela recebe os dados por angle encoding e deve aprender a dependência em x,t diretamente. Não confundir com a QNN auxiliar da MPC.

3. Condições matemáticas e significado da prova

3.1. Espaço-alvo e função de ativação

Os dois alvos usados na primeira etapa são contínuos em domínios compactos. Uma MLP de saída linear e ativação não polinomial apropriada possui resultados clássicos de aproximação universal sob condições padronizadas [3]. A hipótese adicional da prova MPC relatada pela equipe é ativação bijetora; para respeitar isso, as camadas ocultas implementadas usam LeakyReLU com inclinação negativa $\alpha=0{,}1$:

$$\sigma(s) = s \ (s \geq 0), \qquad \sigma(s) = \alpha s \ (s < 0), \ \alpha > 0$$

Essa ativação é bijetora de R em R e contínua; porém não é diferenciável em s=0. Portanto, se a prova de vocês exigir classe C^1/C^k, é necessário substituí-la por uma função suave e bijetora, como asinh(s), e rever as demais hipóteses. Bijetividade isoladamente não implica aproximação universal.

3.2. Um argumento construtivo de expressividade

Considere a média MPC e suponha que a família quântica permita pelo menos um coeficiente fixo não nulo, por exemplo $a_1=q_1\neq 0$. Basta aproximar $y_1(x,t)\approx Nf(x,t)/a_1-1$ e definir $y_i\approx -1$ para $i\geq 2$. Então a MPC aproxima f com a mesma precisão proporcionada pela MLP principal. Essa observação explica de maneira simples como a MPC pode herdar a expressividade clássica em domínio compacto.

O argumento não estabelece que os circuitos aprendam de forma eficiente, que o uso de todas as ordens seja necessário, nem que exista vantagem quântica. A prova formal completa mencionada pela equipe não foi anexada como manuscrito matemático; é preciso conferir suas hipóteses e o enunciado antes de citá-la como um teorema do projeto.

3.3. O que os circuitos de fato acrescentam

Como q_i é independente de x,t, podemos definir $a_i=q_i^i/N$ e reescrever a saída como uma combinação linear com coeficientes globais das respostas da MLP principal:

$$\widehat{u}(x,t) = \sum_{i=1}^{N} a_i \left[1 + y_i(x,t;\theta)\right]$$

Se a última camada clássica for linear, tal combinação pode ser absorvida por uma camada linear convencional. Assim, a diferença fundamental é a parametrização e a geometria de otimização dos coeficientes, não o aparecimento de novas variáveis de entrada quânticas. Isso justifica, em uma segunda etapa, incluir um controle com coeficientes escalares diretamente treináveis.

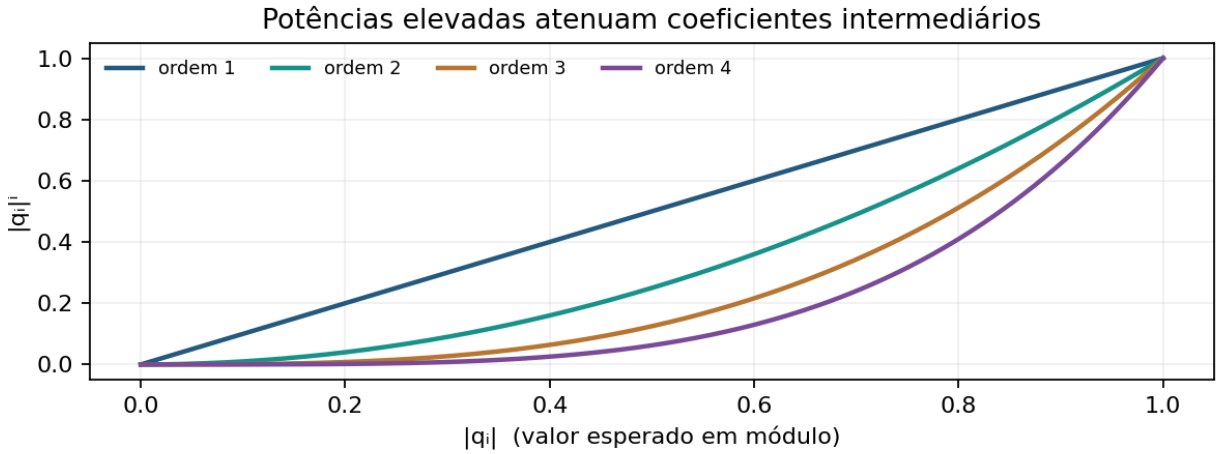
4. Gradientes, ordem crescente e riscos de treinamento

A potência i altera tanto o valor do coeficiente quanto a sensibilidade aos parâmetros do circuito. Suprimindo a dependência nas demais variáveis, a derivada do termo i em relação a φ_i contém o fator:

$$\frac{\partial \widehat{u}}{\partial \phi_i} = \frac{i}{N}(1 + y_i)\, q_i^{i-1} \frac{\partial q_i}{\partial \phi_i}$$

$$\frac{\partial \widehat{u}}{\partial \theta} = \frac{1}{N} \sum_{i=1}^{N} q_i^{i} \frac{\partial y_i}{\partial \theta}$$

Se $|q_i|<1$ de forma persistente, o fator $|q_i|^i$ e frequentemente $i|q_i|^{i-1}$ diminuem rapidamente com a ordem. Quando $|q_i|$ se aproxima de 1, as potências sobrevivem, mas alguns circuitos podem apresentar pouca sensibilidade paramétrica. Logo, não existe garantia automática de treinamento estável.



Relação com barren plateaus

Os fenômenos de barren plateau dependem de distribuição dos circuitos, observáveis, profundidade e função de custo [4,5]. Em particular, palavras globais como Z⊗Z⊗Z e observáveis locais como Z⊗I⊗I devem ser testadas separadamente. Um limite superior para a norma do gradiente não demonstra, por si só, um limite inferior nem exclui gradientes exponencialmente pequenos.

Registros obrigatórios: a cada época salvar q_i, q_i^i, q_i^i/N, norma do gradiente auxiliar, norma total, MSE de treino e validação, learning rate e tempo de treinamento. Isso permite verificar se alguma ordem se tornou inativa.

5. Problemas supervisionados iniciais

A. Burgers viscoso 1D

$$u_t + u\,u_x = \nu u_{xx} \qquad (\nu > 0)$$

Para produzir alvos analíticos sem resolver numericamente a PDE a cada época, usamos uma solução obtida pela transformação de Cole–Hopf [6,7]:

$$\varphi(x,t) = b + a\,e^{-\nu\pi^2 t}\cos(\pi x)$$

$$u(x,t) = -2\nu\frac{\partial_x \varphi}{\varphi} = \frac{2\nu a\pi e^{-\nu\pi^2 t}\sin(\pi x)}{b + a e^{-\nu\pi^2 t}\cos(\pi x)}$$

Escolhas: x,t∈[0,1], ν=0,05, a=0,9, b=1. Exigimos b>|a| para manter φ estritamente positiva; a solução satisfaz u(0,t)=u(1,t)=0. A rede recebe (x,t) normalizados e é supervisionada pela expressão exata.

B. Black–Scholes: call europeia

$$\partial_\tau C = \frac{\sigma^2 S^2}{2} C_{SS} + rSC_S - rC$$

$$C(S,\tau) = S\,\Phi(d_1) - Ke^{-r\tau}\Phi(d_2)$$

$$d_1 = \frac{\ln(S/K) + (r + \sigma^2/2)\tau}{\sigma\sqrt{\tau}}, \qquad d_2 = d_1 - \sigma\sqrt{\tau}$$

Escolhas: S∈[60,140], τ∈[0,1], K=100, r=0,05, σ=0,20; call sem dividendos. A saída é normalizada por K para treinamento. Para τ=0 usamos exatamente o payoff max(S−K,0). A região perto de S=K e τ→0 deve receber avaliação específica, pois existe uma quina no payoff terminal [8].

Em ambos os casos, não há função de perda física. As equações diferenciais justificam a solução de referência e a interpretação dos dados, mas não entram no gradiente do treinamento.

6. Projeto de código: pequeno, mas completo

A organização proposta preserva o estilo dos protótipos anteriores do grupo: PyTorch com autograd e statevector, funções pequenas e arquivos separados apenas quando representam responsabilidades diferentes. Não usaremos PennyLane, Qiskit ou múltiplos scripts de execução.

Arquivo	Responsabilidade
run.py	Único CLI; lê YAML e percorre problemas, modelos, sementes, ablações.
config.yaml	Dados, arquitetura, observáveis, treino, scheduler, GPU e ablações.
mpc/models.py	MLP, MPC clássica, MPC híbrida, QNN e simulador quântico.
mpc/problems.py	Burgers e Black–Scholes analíticos; treino, validação e teste.
mpc/train.py	Adam, MSE, seleção por validação, métricas e gráficos.
tests/test_models.py	Forma, gradiente, qubits por ordem, sem entrada auxiliar e registros.
requirements.txt	torch, PyYAML e matplotlib.

Interface única

python run.py — roda os dois problemas e quatro arquiteturas. **python run.py --problem burgers** — restringe a Burgers. **python run.py --ablations** — executa também os controles definidos no mesmo YAML.

Cálculo quântico no PyTorch

Cada circuito i inicia em $|0\ldots0\rangle$, aplica camadas RY/RZ com parâmetros próprios, conectores CZ e calcula $\mathrm{Tr}[\rho_i P_i]$ pelo vetor de estado. O autograd diferencia naturalmente os ângulos e os pesos clássicos. A simulação exata consome memória $O(2^i)$ por circuito; portanto, N pequeno (1–4) é adequado à versão inicial, especialmente em CPU.

Resultados em disco

- summary.csv: comparativo de RMSE, erro relativo L2, MAE, número de parâmetros, tempo e melhor época.
- history.csv e loss.png: séries de treino, validação, gradientes e learning rate.
- expectations.csv: q_i, q_i^i e q_i^i/N, por época; auxílio para detectar congelamento de ordens.
- solution.png, predictions.csv e best.pt: comparação com a solução analítica, mapa de erro e pesos selecionados.

O parâmetro device: auto escolhe CUDA se existir, caso contrário CPU; o código falha explicitamente se CUDA for solicitada mas indisponível. No ambiente atual, os testes unitários passaram em CPU; o teste CUDA foi corretamente ignorado por falta de GPU.

7. Protocolo justo de comparação

A pesquisa deve ser executada em duas etapas: primeiro verificar que tudo funciona e produz sinais interpretáveis; depois realizar comparações estatísticas controladas. O mesmo conjunto de dados, as mesmas métricas e o mesmo orçamento de treinamento devem ser compartilhados entre as alternativas sempre que a comparação exigir.

Etapa	Modelos / desenho	Propósito
Teste mínimo	MLP; MPC clássica; MPC híbrida; QNN com entrada	Confirmação funcional e gráficos.
Repetições	5 sementes ou mais; mesmas amostras por semente	Variabilidade de convergência e erro.
Controle de parâmetros	Ajuste de largura/profundidade para orçamento parecido	Evitar vantagem por maior número de pesos.
Controle dos coeficientes	Adicionar futuramente MPC com escalares treináveis	Isolar parametrização quântica.
Controle de recursos	Tempo de parede, parâmetros, qubits e memória	Avaliar custo-benefício real.

Métricas de análise

RMSE, MAE e erro relativo L2 no grid de teste; perda de validação; época para atingir limiares de erro pré-definidos; tempo total; gradientes das duas partes; amplitude e mudança dos coeficientes; desempenho perto das regiões difíceis (Burgers mais íngreme e Black–Scholes próximo do strike com baixa maturidade).

O que manter fixo entre experimentos

• Mesmos pontos de treino e validação em cada semente; grid de teste nunca usado para escolha de hiperparâmetros.

• Mesmos limites de domínio e normalização das entradas; Black–Scholes treinado em C/K.

• Controle da largura, profundidade, épocas, batch size, learning rate e scheduler no YAML; registrar qualquer exceção.

• Conservar os resultados negativos e positivos; relatar média e dispersão entre sementes, não apenas melhor execução.

8. Ablações: perguntas que fazem sentido

Variável	Valores de partida	Pergunta
Número de termos N	1, 2, 3, 4	Ordens adicionais ajudam ou se anulam?
Profundidade quântica	1, 2, 4 camadas	Maior expressividade melhora ou prejudica treinamento?
Observáveis	Z, ZZ, ZZZ vs. Z, ZI, ZII	Globalidade ou localidade alteram gradientes?
Parâmetros quânticos	Treináveis vs. congelados	O circuito precisa ser otimizado?
Potências	q_i^i vs. q_i	Qual o efeito real do termo polinomial?
Agregação	mean vs. sum	Muda a escala de saída e a dinâmica de otimização?
MLP principal	W = 8,16,32; L = 1,2,3	Ganho depende da capacidade clássica?
Otimização	LR=1e−3/3e−3; scheduler sim/não	Estabilidade contra escolhas do otimizador?
Amostras	128, 256, 512	Sensibilidade à quantidade de dados supervisionados?

Ordem prioritária para não multiplicar experimentos

Fase 0: N=3, duas camadas quânticas e quatro modelos nos dois problemas; salvar todos os diagnósticos. Fase 1: variar observável, circuito congelado e potências. Fase 2: aumentar N, profundidade e repetir sementes. Fase 3: controles de igualdade aproximada de parâmetros e de tempo.

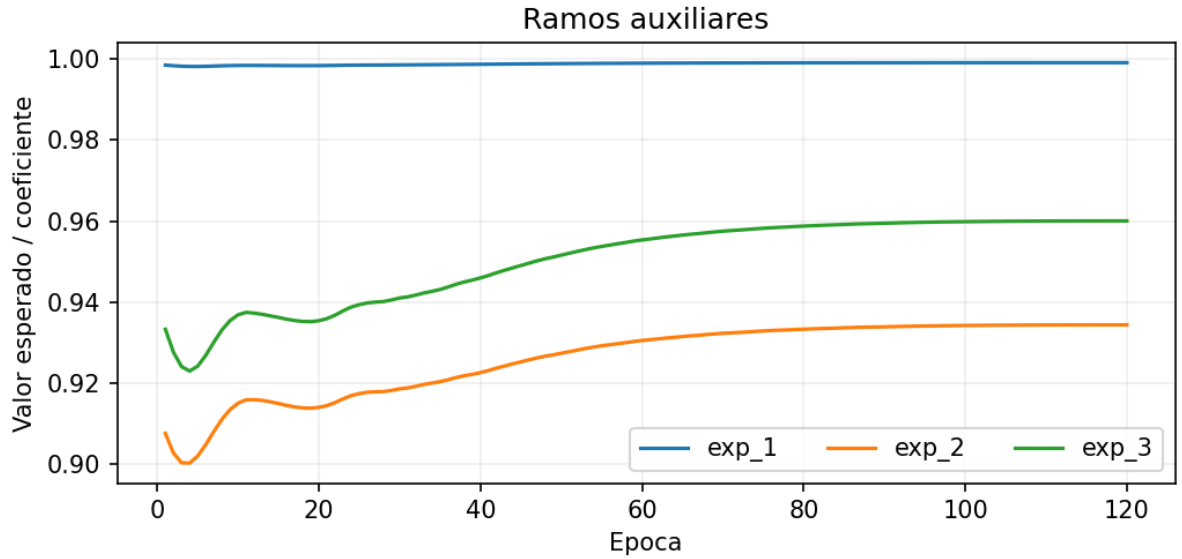
O mesmo run.py processa todos os cenários; não se criam múltiplos arquivos de execução. As ablações são variações declarativas do YAML, sem duplicação das rotinas de treino.

9. Validação preliminar do protótipo

Uma rodada rápida, uma única semente, foi executada em CPU apenas para confirmar comportamento e persistência dos arquivos. Condições: 120 épocas, 256 pontos de treino, 128 de validação, grid 40×40, Adam com LR=0,003 e scheduler cosseno; N=3 na MPC, camadas quânticas=2.

Problema	MLP	MPC clássica	MPC híbrida	QNN
Burgers 1D	0,06487	0,02818	0,02522	0,27088
Black–Scholes	0,00770	0,00437	0,00880	0,26441

Tabela: RMSE no teste. Em Black–Scholes os erros são relativos à variável C/K (não são unidades monetárias). Uma execução curta e com número de parâmetros muito diferente entre os modelos não autoriza afirmar superioridade. Em particular, a MPC híbrida teve menor RMSE que a MPC clássica em Burgers, mas maior erro em Black–Scholes; resultados podem mudar com mais épocas e sementes.



Exemplo do monitoramento: valores esperados auxiliares ao longo das épocas (Burgers, teste rápido). A curva é função do índice de treinamento, e não de x,t.

Leitura científica apropriada

Esses dados validam a construção e mostram que a comparação é viável. A próxima etapa não deve ser escolher o modelo “vencedor”, mas fazer os controles de coeficientes, observáveis e repetições para identificar se diferenças são persistentes e por que ocorrem.

10. Conclusões e critérios de avanço

A proposta faz sentido como estudo controlado de uma arquitetura MPC híbrida sem data encoding quântico. A contribuição potencial está em compreender a parametrização dos coeficientes por circuitos em dimensões crescentes e potências crescentes, não em resolver uma PDE por residual físico nem em produzir operadores quânticos dependentes de coordenadas.

O que considerar um resultado relevante

• Uma melhora de erro repetida em múltiplas sementes e domínios, após controlar o número de parâmetros.

• Uma mudança interpretável nas trajetórias q_i, nos gradientes auxiliares e na contribuição de cada ordem.

• Evidência de que o circuito treinável adiciona algo além de um conjunto de coeficientes fixos ou diretamente treináveis.

• A análise de custo, documentando a penalidade exponencial da simulação por vetor de estado conforme N aumenta.

Limitações atuais a declarar

O enunciado formal e a demonstração matemática da equipe ainda precisam ser incorporados ao repositório para revisão das hipóteses de bijetividade e regularidade. A QNN convencional do teste mínimo tem orçamento de parâmetros muito inferior ao de uma MLP, de modo que é apenas uma referência estrutural; resultados justos exigem um protocolo de capacidade parecida. Testes CUDA permanecem pendentes de hardware disponível.

Decisão sugerida: manter uma base única e pequena de código; completar primeiro o estudo de Burgers 1D e Black–Scholes; só depois ampliar para Burgers 2D/3D ou outras PDEs.

11. Referências selecionadas

As referências abaixo foram selecionadas para fundamentar a arquitetura, os riscos de treinabilidade e as duas soluções analíticas. O material interno do INCT define as escolhas específicas do projeto.

[1] Lantigua, S.; Giraldi, G.; Portugal, R. Classical-quantum hybrid architecture for physics-informed neural networks. Physical Review A 113, 042446 (2026). DOI: 10.1103/fdd3-qz1s.

[2] Lantigua, S. et al. QPI-DeepONet-MAC: A Scalable and Stable Hybrid Classical-Quantum Architecture for Physics-Informed Deep Operator Networks. arXiv:2610.01824v1 (2026).

[3] Leshno, M.; Lin, V. Y.; Pinkus, A.; Schocken, S. Multilayer feedforward networks with a nonpolynomial activation function can approximate any function. Neural Networks 6, 861–867 (1993). DOI: 10.1016/S0893-6080(05)80131-5.

[4] McClean, J. R. et al. Barren plateaus in quantum neural network training landscapes. Nature Communications 9, 4812 (2018). DOI: 10.1038/s41467-018-07090-4.

[5] Cerezo, M. et al. Cost function dependent barren plateaus in shallow parametrized quantum circuits. Nature Communications 12, 1791 (2021). DOI: 10.1038/s41467-021-21728-w.

[6] Hopf, E. The partial differential equation u_t + u u_x = μ u_xx. Communications on Pure and Applied Mathematics 3, 201–230 (1950). DOI: 10.1002/cpa.3160030302.

[7] Cole, J. D. On a quasi-linear parabolic equation occurring in aerodynamics. Quarterly of Applied Mathematics 9, 225–236 (1951). DOI: 10.1090/qam/42889.

[8] Black, F.; Scholes, M. The Pricing of Options and Corporate Liabilities. Journal of Political Economy 81(3), 637–654 (1973). DOI: 10.1086/260062.

[9] INCT. Rascunho interno: arquiteturas MLP / MPC clássica / MPC híbrida e problemas de referência. Material fornecido pela equipe (2026).